Analyse des Résiliations de Cartes de Crédit

Chargement des données

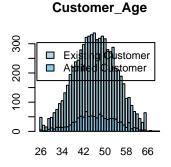
```
library(ggplot2)
library(skimr)
library(VIM)
library(outliers)
library(psych)

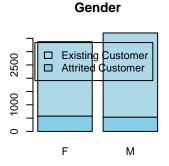
# Chargement des données
tab <- read.csv(file = "./data/credit-card-customers/cleaned_data.csv", sep = ',', dec = '.', header = '.'</pre>
```

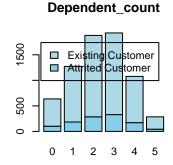
Objectif 1: Compréhension des caractéristiques démographiques

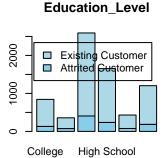
```
# Profils démographiques des clients résiliant leurs services de cartes de crédit
par(mfrow = c(2, 3))

# Analyse univariée pour chaque variable démographique
for (var in c("Customer_Age", "Gender", "Dependent_count", "Education_Level", "Marital_Status", "Income barplot(table(tab$Attrition_Flag, tab[[var]]), main = var, col = c("skyblue", "lightblue"), legend.te
}
```

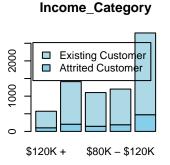












Objectif 2: Étude des relations entre les variables

```
# Matrice de corrélation pour les variables démographiques et transactionnelles
correlation_matrix <- cor(tab[, c("Customer_Age", "Dependent_count", "Credit_Limit", "Total_Trans_Amt",</pre>
# Affichage de la matrice de corrélation
print(correlation_matrix)
##
                   Customer_Age Dependent_count Credit_Limit Total_Trans_Amt
                     1.0000000
                                     -0.12800966
                                                   0.02476095
                                                                   -0.04587715
## Customer_Age
## Dependent_count
                                      1.00000000
                                                   0.08134262
                                                                    0.02318343
                    -0.12800966
## Credit_Limit
                     0.02476095
                                      0.08134262
                                                   1.00000000
                                                                    0.17186820
## Total_Trans_Amt -0.04587715
                                      0.02318343
                                                   0.17186820
                                                                    1.00000000
## Total_Trans_Ct
                    -0.06987182
                                      0.05692060
                                                   0.08135287
                                                                    0.81010676
##
                   Total_Trans_Ct
                      -0.06987182
## Customer_Age
## Dependent_count
                       0.05692060
## Credit_Limit
                       0.08135287
## Total_Trans_Amt
                       0.81010676
## Total_Trans_Ct
                       1.0000000
# Test de corrélation entre variables
cor.test(tab$Customer_Age, tab$Total_Trans_Amt)
```

##
Pearson's product-moment correlation

```
##
## data: tab$Customer_Age and tab$Total_Trans_Amt
## t = -3.8635, df = 7077, p-value = 0.0001128
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.06909899 -0.02260562
## sample estimates:
## cor
## -0.04587715
```

Objectif 3: Facteurs sous-jacents à la résiliation

```
# Sélection des variables pertinentes pour l'analyse factorielle
selected_vars <- c("Customer_Age", "Credit_Limit", "Total_Trans_Amt")</pre>
# Résumé statistique des colonnes sélectionnées
summary(tab[, selected_vars])
##
                    Credit_Limit
                                   Total_Trans_Amt
    Customer_Age
## Min.
          :26.00
                  Min. : 1438
                                   Min. : 510
## 1st Qu.:41.00 1st Qu.: 2496
                                   1st Qu.: 2090
## Median :46.00 Median : 4287
                                   Median: 3831
## Mean :46.35 Mean : 8490
                                   Mean : 4395
## 3rd Qu.:52.00 3rd Qu.:10708
                                   3rd Qu.: 4740
          :73.00 Max.
                          :34516
                                         :17995
## Max.
                                   Max.
# Analyse factorielle pour réduire la dimensionnalité des données
nb_facteurs <- 2  # Nombre de facteurs à extraire
fact_model <- fa(tab[, selected_vars], nfactors = nb_facteurs, rotate = "varimax")</pre>
# Affichage des résultats de l'analyse factorielle
print(fact_model)
## Factor Analysis using method = minres
## Call: fa(r = tab[, selected_vars], nfactors = nb_facteurs, rotate = "varimax")
## Standardized loadings (pattern matrix) based upon correlation matrix
##
                    MR1
                          MR2
                                 h2
                                      u2 com
## Customer_Age
                  -0.01 0.30 0.088 0.91 1.0
## Credit_Limit
                  0.43 0.09 0.196 0.80 1.1
## Total_Trans_Amt 0.43 -0.14 0.205 0.80 1.2
##
##
                         MR1 MR2
## SS loadings
                        0.37 0.12
## Proportion Var
                        0.12 0.04
## Cumulative Var
                        0.12 0.16
## Proportion Explained 0.76 0.24
## Cumulative Proportion 0.76 1.00
## Mean item complexity = 1.1
## Test of the hypothesis that 2 factors are sufficient.
```

```
## df null model = 3 with the objective function = 0.03 with Chi Square = 234.87
## df of the model are -2 and the objective function was 0
## The root mean square of the residuals (RMSR) is 0
## The df corrected root mean square of the residuals is \, NA
## The harmonic n.obs is 7079 with the empirical chi square 0 with prob < NA
## The total n.obs was 7079 with Likelihood Chi Square = 0 with prob < NA
## Tucker Lewis Index of factoring reliability = 1.013
## Fit based upon off diagonal values = 1
## Measures of factor score adequacy
                                                      MR1
                                                           MR2
## Correlation of (regression) scores with factors
                                                     0.56 0.34
## Multiple R square of scores with factors
                                                     0.32 0.12
                                                   -0.37 -0.77
## Minimum correlation of possible factor scores
```

Objectif 4: Modélisation prédictive

Transformation de la variable Attrition Flag en binaire

```
tab$Attrition_Flag <- ifelse(tab$Attrition_Flag == "Attrited Customer", 1, 0)
# Modèle de régression logistique, prédictive pour estimer la probabilité de résiliation
model <- glm(Attrition_Flag ~ Customer_Age + Dependent_count + Credit_Limit + Total_Trans_Amt + Total_T
# Affichage des résultats du modèle
summary(model)
##
## Call:
## glm(formula = Attrition_Flag ~ Customer_Age + Dependent_count +
      Credit_Limit + Total_Trans_Amt + Total_Trans_Ct, family = "binomial",
##
      data = tab)
##
## Coefficients:
##
                    Estimate Std. Error z value Pr(>|z|)
                   2.360e+00 2.592e-01
                                        9.104 < 2e-16 ***
## (Intercept)
## Customer_Age
                  -9.097e-03 4.462e-03 -2.039 0.041458 *
## Dependent_count 1.108e-01 2.889e-02
                                         3.835 0.000125 ***
                  -1.164e-05 4.300e-06 -2.707 0.006790 **
## Credit_Limit
## Total_Trans_Amt 4.004e-04 2.112e-05 18.958 < 2e-16 ***
## Total_Trans_Ct -9.493e-02 3.295e-03 -28.814 < 2e-16 ***
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.05 '.' 0.1 ' ' 1
## (Dispersion parameter for binomial family taken to be 1)
##
      Null deviance: 6159.3 on 7078 degrees of freedom
## Residual deviance: 4804.0 on 7073 degrees of freedom
## AIC: 4816
```

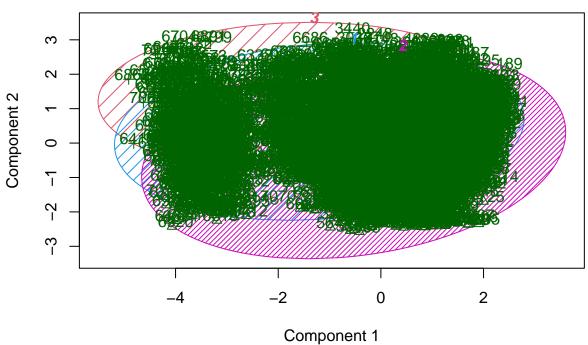
```
##
## Number of Fisher Scoring iterations: 6
```

Objectif 5: Classification des clients

```
# Utilisation de méthodes de classification (par exemple, k-means)
set.seed(123) # Pour la reproductibilité
num_clusters <- 3</pre>
cluster vars <- tab[, c("Customer Age", "Credit Limit", "Total Trans Amt", "Total Trans Ct")]</pre>
# Algorithme de k-means
kmeans_model <- kmeans(cluster_vars, centers = num_clusters, nstart = 20)</pre>
# Affichage des résultats de la classification
print(kmeans_model)
## K-means clustering with 3 clusters of sizes 1377, 4964, 738
##
## Cluster means:
 Customer_Age Credit_Limit Total_Trans_Amt Total_Trans_Ct
## 1
   46.45389
       13980.772
             5173.005
                   66.97313
## 2
   46.23832
       3604.487
             3989.158
                   63.13578
## 3
   46.88482
       31109.801
             5674.447
                   69.21274
##
## Clustering vector:
##
   [38] \ \ 3\ 1\ 3\ 2\ 2\ 2\ 3\ 3\ 2\ 2\ 2\ 2\ 2\ 3\ 2\ 1\ 2\ 1\ 1\ 3\ 2\ 2\ 2\ 2\ 2\ 1\ 2\ 2\ 3\ 1\ 2\ 2 
##
##
 ## [186] 2 2 2 2 2 2 2 2 2 2 2 2 2 2 2 3 2 2 2 2 2 2 2 2 2 2 2 3 2 1 1 3 2 2 2 1 1 2
##
## [593] 2 3 2 2 3 2 2 2 2 1 1 2 2 2 1 1 2 2 2 1 1 2 2 2 2 2 2 2 2 2 2 2 1 2 1 3 2 3 3
##
 ##
 ##
```

```
 \begin{smallmatrix} 6994 \end{smallmatrix} \rbrack \hspace*{0.5em} 2 \hspace*{0.5em} 2 \hspace*{0.5em} 2 \hspace*{0.5em} 2 \hspace*{0.5em} 1 \hspace*{0.5em} 2 \hspace*{0
              [7031] \ 2 \ 2 \ 3 \ 2 \ 1 \ 2 \ 2 \ 1 \ 1 \ 2 \ 2 \ 1 \ 3 \ 2 \ 2 \ 1 \ 3 \ 3 \ 2 \ 1 \ 1 \ 2 \ 3 \ 1 \ 1 \ 3 \ 3 \ 2 \ 2 \ 1 \ 1 \ 2 \ 3
              [7068] 2 3 1 2 2 1 1 1 2 2 2 1
##
## Within cluster sum of squares by cluster:
             [1] 47106841027 59161782918 27891462441
                     (between_SS / total_SS = 80.1 %)
##
##
             Available components:
## [1] "cluster"
                                                                                                                       "centers"
                                                                                                                                                                                                       "totss"
                                                                                                                                                                                                                                                                                                                                                                        "tot.withinss"
                                                                                                                                                                                                                                                                                       "withinss"
               [6] "betweenss"
                                                                                                                                                                                                       "iter"
                                                                                                                       "size"
                                                                                                                                                                                                                                                                                       "ifault"
# Visualisation en 2D des clusters créés par k-means
library(cluster)
par(mfrow = c(1, 1))
clusplot(cluster_vars, kmeans_model$cluster, color=TRUE, shade=TRUE, labels=2, lines=0)
```

CLUSPLOT(cluster_vars)



These two components explain 71.98 % of the point variability.

TODO:

Objectif 1: Compréhension des caractéristiques démographiques

Profils démographiques des clients résiliant leurs services de cartes de crédit L'analyse univariée des caractéristiques démographiques des clients permet de visualiser la distribution des résiliations pour chaque variable. Voici quelques observations :

- Customer Age: La répartition des résiliations semble similaire pour différentes tranches d'âge.
- Gender : Les résiliations semblent réparties de manière équivalente entre les genres.
- Dependent_count : La plupart des clients ayant résilié ont un faible nombre de personnes à charge.
- Education_Level : Les clients ayant résilié proviennent de divers niveaux d'éducation, mais les diplômés universitaires semblent être légèrement plus nombreux.
- Marital_Status: Les clients célibataires semblent plus enclins à résilier.
- Income Category: Les résiliations sont plus fréquentes chez les clients ayant des revenus modérés.

Objectif 2: Étude des relations entre les variables

La matrice de corrélation montre les relations linéaires entre les variables démographiques et transactionnelles. Par exemple, nous pouvons observer une corrélation négative entre l'âge du client et le total des transactions effectuées.

La corrélation entre l'âge du client et le montant total des transactions est statistiquement significative (p-value < 0.05), ce qui suggère une relation linéaire négative.

Objectif 3: Facteurs sous-jacents à la résiliation

L'analyse factorielle avec rotation varimax sur les variables sélectionnées (Customer_Age, Credit_Limit, Total_Trans_Amt) réduit la dimensionnalité des données. Les résultats montrent les facteurs sous-jacents aux caractéristiques sélectionnées, mais il est essentiel d'interpréter ces facteurs en fonction du contexte.

Objectif 4: Modélisation prédictive

Le modèle de régression logistique est utilisé pour estimer la probabilité de résiliation en fonction des variables disponibles. Les coefficients du modèle indiquent l'impact de chaque variable sur la probabilité de résiliation. Une analyse plus approfondie des résultats, notamment des p-values, est nécessaire pour évaluer la significativité des coefficients.

Objectif 5: Classification des clients

L'utilisation de l'algorithme de classification k-means regroupe les clients en clusters distincts en fonction de leurs caractéristiques. La visualisation en 2D des clusters montre comment les clients sont regroupés en fonction de l'âge, du montant de crédit, du total des transactions, et du total des transactions effectuées. Cette classification peut aider à identifier des segments de clients ayant des comportements similaires.

Ces résultats fournissent une base pour mieux comprendre les caractéristiques des clients associées à la résiliation des services de cartes de crédit et pour développer des stratégies visant à réduire la résiliation. Il est recommandé d'approfondir l'analyse, d'évaluer la performance du modèle prédictif sur un ensemble de test distinct et de vérifier la stabilité des clusters au fil du temps.